

JIRA Data Engineering Pipeline – Medallion Architecture

This project implements a robust Data Engineering pipeline to process JIRA data, utilizing the Medallion Architecture to transform raw data into business intelligence regarding SLA (Service Level Agreement).

us English Version

Objective

This project automates the ingestion and processing of JIRA tickets to calculate resolution time in **business hours**, excluding weekends and national holidays.

Pipeline Architecture

The project follows the **Medallion Architecture**:

- **Bronze Layer**: Raw ingestion from Azure Blob Storage using Service Principal authentication.
- **Silver Layer**: Data cleaning, normalization, and conversion to **Parquet** format for performance.
- **Gold Layer**: Business rules application and SLA calculation based on priority, integrated with **BrasilAPI**.
- **Data Quality**: Automated auditing of integrity, volume, and null validation.

Dashboard & Visualization (Streamlit)

Interactive interface for performance management:

- **Dynamic Filters**: Date Range, Issue Type, and Analyst.
- **Trend Analysis**: Monthly SLA compliance tracking.
- **Performance Ranking**: Automated analyst classification (Top Performer, Standard, Needs Support).

Technologies & Best Practices

- **Python 3.x** and **Pandas** for data manipulation.
- **Streamlit & Plotly** for visualization and interactive dashboards.
- **PyArrow**: Stable Parquet write engine.
- **Security**: Use of environment variables (**.env**) and sensitive data protection via **.gitignore**.

Execution Evidence & Quality

The pipeline features a central orchestrator that validates each stage. In test runs:

- **Data Funnel**: 1000 raw records → 990 valid records → 804 finalized tickets.
- **Auditing**: 100% validation of priority rules and chronological integrity.

Environment Setup Guide

How to Run

1. Open CMD (Command Prompt):

Use the cd command in CMD:

```
cd "C:\Users\Alex Lourenço\Desktop\project-root" <----- UPDATE TO YOUR ACTUAL PATH
```

2. Run Automatic Setup: `python init_project.py`

Run the master script. It will create the venv folder, install dependencies from requirements.txt, and ask for your credentials to set up the .env file.

3. Execution Workflow

Whenever you use the project, follow this order in the terminal:

1. Activate Environment: `venv\Scripts\activate`

2. Run Pipeline: `python main.py`

3. Open Dashboard: `streamlit run app.py`

BR Versão em Português

Objetivo

O objetivo deste projeto é automatizar a ingestão e o processamento de chamados do JIRA para calcular o tempo de resolução em **horas úteis**, desconsiderando finais de semana e feriados nacionais.

Arquitetura do Pipeline

O projeto segue a **Arquitetura Medallion**, garantindo organização e rastreabilidade:

- **Camada Bronze:** Ingestão de arquivos JSON brutos do Azure Blob Storage utilizando autenticação via Service Principal.
- **Camada Silver:** Limpeza e normalização dos dados. Extração de campos aninhados (`assignee`, `timestamps`) e conversão para o formato **Parquet** visando performance e preservação de metadados.
- **Camada Gold:** Aplicação de regras de negócio. Cálculo de SLA baseado na prioridade (High: 24h, Medium: 72h, Low: 120h), integrando com a **BrasilAPI** para identificação de feriados.
- **Data Quality:** Auditoria automática de integridade, volumetria e validação de nulos ao final do processo.

Dashboard e Visualização (Streamlit)

O projeto inclui uma interface interativa para gestão de performance, permitindo:

- **Filtros Dinâmicos:** Seleção por Período, Tipo de Chamado e Analista.
- **Análise de Tendência:** Gráfico mensal de conformidade de SLA.

- **Ranking de Performance:** Classificação automática de analistas com status de suporte (Top Performer, Standard, Needs Support).

Tecnologias e Boas Práticas

- **Python 3.x** e **Pandas** para manipulação de dados.
- **Streamlit & Plotly** para visualização e dashboards interativos.
- **PyArrow:** Engine de escrita Parquet estável.
- **Segurança:** Uso de variáveis de ambiente (**.env**) e proteção de dados sensíveis via **.gitignore**.

Evidências de Execução e Qualidade

O pipeline conta com um orquestrador central que valida cada etapa. Em execuções de teste:

- **Funil de Dados:** Ingestão de 1000 registros → 990 registros válidos → 804 chamados finalizados.
- **Auditoria:** Validação de 100% das regras de prioridade e integridade cronológica.

Guia de Configuração do Ambiente (Setup)

Siga estas etapas para configurar o ambiente automaticamente via CMD/Terminal utilizando o **Python 3.12.:**

Como Executar

1. Abra o CMD (Prompt de Comando):

Use o comando cd no CMD (Prompt de Comando):

`cd "C:\Users\Alex Lourenço\Desktop\project-root"` <----- **ATUALIZE O SEU ENDEREÇO**

2. Executar o Setup Automático `python init_project.py`

Rode o script mestre. Ele criará a pasta venv, instalará as dependências do requirements.txt e solicitará suas credenciais para o arquivo .env:

3. Fluxo de Execução

Sempre que for utilizar o projeto, siga esta ordem no terminal:

1. Ativar Ambiente: `venv\Scripts\activate`

2. Rodar Pipeline: `python main.py`

3. Abrir Dashboard: `streamlit run app.py`

Estrutura de Pastas / Project Structure

```
PROJECT-ROOT/
├── .pycache/           # Arquivos de cache do Python (Ignorado)
├── data/               # Armazenamento Local / Local Storage (Ignorado)
├── src/                # Código-fonte principal / Source Code
│   ├── __pycache__/    # Cache interno da src
│   ├── bronze/         # Camada de Ingestão (JSON Raw)
│   └── __pycache__/
```

```
| | | └─ ingest_bronze.py
| | └─ silver/           # Camada de Limpeza e Transformação (Parquet)
| | └─ gold/            # Camada de Regras de Negócio / Analytics
| | └─ sla_calculation.py # Motor de Cálculo de SLA
| | └─ validate_pipeline.py # Auditoria e Validação de Dados
| └─ venv/              # Ambiente Virtual Python (Local)
| └─ .env               # Variáveis de ambiente e Credenciais
| └─ .gitignore         # Configuração de arquivos ignorados pelo Git
| └─ .python-version    # Definição da versão do Python (Ex: 3.12)
| └─ app.py             # Interface do Dashboard (Streamlit)
| └─ init_project.py    # Script de inicialização/setup do projeto
| └─ main.py            # Orquestrador Central / Ponto de Entrada
| └─ README.md          # Documentação principal (Markdown)
| └─ README.pdf         # Exportação da documentação em PDF
| └─ requirements.txt   # Lista de dependências do projeto
```