

JIRA Data Engineering Pipeline – Medallion Architecture

Este projeto implementa um pipeline de Engenharia de Dados robusto para processar dados do JIRA, utilizando a Arquitetura Medallion para transformar dados brutos em inteligência de negócios sobre SLA (Service Level Agreement).

BR Versão em Português

Objetivo

O objetivo deste projeto é automatizar a ingestão e o processamento de chamados do JIRA para calcular o tempo de resolução em **horas úteis**, desconsiderando finais de semana e feriados nacionais.

Arquitetura do Pipeline

O projeto segue a **Arquitetura Medallion**, garantindo organização e rastreabilidade:

- **Camada Bronze:** Ingestão de arquivos JSON brutos do Azure Blob Storage utilizando autenticação via Service Principal.
- **Camada Silver:** Limpeza e normalização dos dados. Extração de campos aninhados (`assignee`, `timestamps`) e conversão para o formato **Parquet** visando performance e preservação de metadados.
- **Camada Gold:** Aplicação de regras de negócio. Cálculo de SLA baseado na prioridade (High: 24h, Medium: 72h, Low: 120h), integrando com a **BrasilAPI** para identificação de feriados.
- **Data Quality:** Auditoria automática de integridade, volumetria e validação de nulos ao final do processo.

Dashboard e Visualização (Streamlit)

O projeto inclui uma interface interativa para gestão de performance, permitindo:

- **Filtros Dinâmicos:** Seleção por Período, Tipo de Chamado e Analista.
- **Análise de Tendência:** Gráfico mensal de conformidade de SLA.
- **Ranking de Performance:** Classificação automática de analistas com status de suporte (Top Performer, Standard, Needs Support).

Tecnologias e Boas Práticas

- **Python 3.x e Pandas** para manipulação de dados.
- **Streamlit & Plotly** para visualização e dashboards interativos.
- **PyArrow**: Engine de escrita Parquet estável.
- **Segurança:** Uso de variáveis de ambiente (`.env`) e proteção de dados sensíveis via `.gitignore`.

Evidências de Execução e Qualidade

O pipeline conta com um orquestrador central que valida cada etapa. Em execuções de teste:

- **Funil de Dados:** Ingestão de 1000 registros → 990 registros válidos → 804 chamados finalizados.
- **Auditoria:** Validação de 100% das regras de prioridade e integridade cronológica.

🔧 Guia de Configuração do Ambiente (Setup)

Siga estas etapas na ordem exata para garantir a consistência do ambiente utilizando o **Python 3.12**.

1. Selecionar o Interpretador (VS Code)

Antes de criar o ambiente, force o editor a usar a versão correta para evitar conflitos de cache:

1. Pressione **Ctrl + Shift + P** (ou **Cmd + Shift + P** no Mac).
2. Digite **Python: Select Interpreter**.
3. Escolha **Python 3.12.x** na lista.

🚀 Como Executar

1. **Clone o repositório:** `git clone https://github.com/alexlourenc/engenharia_dados.git`
 2. **Configure o Ambiente Virtual:** `py -3.12 -m venv venv` e ative-o (`.\venv\Scripts\Activate.ps1` no Windows ou `source venv/bin/activate` no Linux/Mac).
 3. **Instale as dependências:** `pip install -r requirements.txt`
 4. **Configure o arquivo .env** na raiz do projeto com suas credenciais.
 5. **Execute o orquestrador:** `python main.py`
 6. **Inicie o dashboard:** `streamlit run app.py`
-

us English Version

📋 Objective

This project automates the ingestion and processing of JIRA tickets to calculate resolution time in **business hours**, excluding weekends and national holidays.

🏗 Pipeline Architecture

The project follows the **Medallion Architecture**:

- **Bronze Layer:** Raw ingestion from Azure Blob Storage using Service Principal authentication.
- **Silver Layer:** Data cleaning, normalization, and conversion to **Parquet** format for performance.
- **Gold Layer:** Business rules application and SLA calculation based on priority, integrated with **BrasilAPI**.
- **Data Quality:** Automated auditing of integrity, volume, and null validation.

💻 Dashboard & Visualization (Streamlit)

Interactive interface for performance management:

- **Dynamic Filters:** Date Range, Issue Type, and Analyst.
- **Trend Analysis:** Monthly SLA compliance tracking.
- **Performance Ranking:** Automated analyst classification (Top Performer, Standard, Needs Support).

🛠 Technologies & Best Practices

- **Python 3.x** and **Pandas** for data manipulation.
- **Streamlit & Plotly** for visualization and interactive dashboards.
- **PyArrow**: Stable Parquet write engine.
- **Security**: Use of environment variables (`.env`) and sensitive data protection via `.gitignore`.

📝 Execution Evidence & Quality

The pipeline features a central orchestrator that validates each stage. In test runs:

- **Data Funnel:** 1000 raw records → 990 valid records → 804 finalized tickets.
- **Auditing:** 100% validation of priority rules and chronological integrity.

🛠 Environment Setup Guide

Follow these steps in the exact order to ensure environment consistency using **Python 3.12**.

1. Select the Interpreter (VS Code)

Before creating the environment, force the editor to use the correct version to avoid cache conflicts:

1. Press `Ctrl + Shift + P` (or `Cmd + Shift + P` on Mac).
2. Type `Python: Select Interpreter`.
3. Choose `Python 3.12.x` in the list.

🚀 How to Run

1. **Clone the repository:** `git clone https://github.com/alexlourenc/engenharia_dados.git`
 2. **Configure the Virtual Environment:** `py -3.12 -m venv venv` and activate it (`.\venv\Scripts\Activate.ps1` on Windows or `source venv/bin/activate` on Linux/Mac).
 3. **Install dependencies:** `pip install -r requirements.txt`
 4. **Configure the .env file** in the project root with your credentials.
 5. **Execute the orchestrator:** `python main.py`
 6. **Start the dashboard:** `streamlit run app.py`
-

📁 Estrutura de Pastas / Project Structure

```
PROJECT-ROOT/
├── data/          # Armazenamento Local / Local Storage (Ignorado no Git)
├── src/           # Código-fonte principal / Source Code
│   ├── bronze/    # Ingestão (JSON Raw) / Ingestion
│   └── silver/    # Limpeza e Parquet / Cleaning & Parquet
```

```
|   └── gold/           # Regras de Negócio / Business Rules
|   └── sla_calculation.py  # Motor de Cálculo / Calculation Engine
|   └── validate_pipeline.py # Auditoria de Dados / Data Auditing
└── .env                  # Credenciais e Variáveis de ambiente (Sensitive data)
└── .gitignore            # Proteção de arquivos sensíveis
└── .python-version       # Versão fixa do Python (3.12)
└── app.py                # Interface do Dashboard (Streamlit)
└── main.py               # Orquestrador Central / Main Orchestrator
└── README.md             # Documentação do projeto
└── requirements.txt       # Dependências do projeto
```