

JIRA Data Engineering Pipeline – Medallion Architecture

Este projeto implementa um pipeline de Engenharia de Dados robusto para processar dados do JIRA, utilizando a Arquitetura Medallion para transformar dados brutos em inteligência de negócio sobre SLA (Service Level Agreement).

BR Versão em Português

Objetivo

O objetivo deste projeto é automatizar a ingestão e o processamento de chamados do JIRA para calcular o tempo de resolução em **horas úteis**, desconsiderando finais de semana e feriados nacionais.

Arquitetura do Pipeline

O projeto segue a **Arquitetura Medallion**, garantindo organização e rastreabilidade:

- **Camada Bronze:** Ingestão de arquivos JSON brutos do Azure Blob Storage utilizando autenticação via Service Principal.
- **Camada Silver:** Limpeza e normalização dos dados. Extração de campos aninhados (**assignee**, **timestamps**) e conversão para o formato **Parquet** visando performance e preservação de metadados.
- **Camada Gold:** Aplicação de regras de negócio. Cálculo de SLA baseado na prioridade (High: 24h, Medium: 72h, Low: 120h), integrando com a **BrasilAPI** para identificação de feriados.
- **Data Quality:** Auditoria automática de integridade, volumetria e validação de nulos ao final do processo.

Tecnologias e Boas Práticas

- **Python 3.x** e **Pandas** para manipulação de dados.
- **PyArrow:** Engine de escrita Parquet estável para ambiente Windows.
- **Segurança:** Uso de variáveis de ambiente (**.env**) e proteção de dados sensíveis via **.gitignore**.
- **Modularização:** Código dividido em módulos específicos para cada etapa do processo.

Evidências de Execução e Qualidade

O pipeline conta com um orquestrador central que valida cada etapa. Em execuções de teste, o sistema processou com sucesso:

- **Funil de Dados:** Ingestão de 1000 registros → 990 registros válidos → 804 chamados finalizados para análise de SLA.
- **Auditoria:** Validação de 100% das regras de prioridade e integridade cronológica (Resolução > Criação).

Como Executar

1. Clone o repositório.
2. Instale as dependências: `pip install -r requirements.txt`.
3. Configure o arquivo `.env` na raiz do projeto com suas credenciais do Azure.
4. Execute o orquestrador: `python main.py`.

us English Version

Objective

This project automates the ingestion and processing of JIRA tickets to calculate resolution time in **business hours**, excluding weekends and national holidays.

Pipeline Architecture

The project follows the **Medallion Architecture**, ensuring organization and traceability:

- **Bronze Layer:** Raw ingestion of JSON files from Azure Blob Storage using Service Principal authentication.
- **Silver Layer:** Data cleaning and normalization. Extraction of nested fields (`assignee`, `timestamps`) and conversion to **Parquet** format for performance and metadata preservation.
- **Gold Layer:** Application of business rules. SLA calculation based on priority (High: 24h, Medium: 72h, Low: 120h), integrated with **BrasilAPI** for holiday identification.
- **Data Quality:** Automated auditing of integrity, volume, and null values at the end of the pipeline.

Execution Evidence & Quality

The pipeline includes a central orchestrator that validates each stage. During test runs, the system successfully processed:

- **Data Funnel:** 1000 raw records → 990 valid records → 804 finalized tickets for SLA analysis.
- **Auditing:** 100% validation of priority rules and chronological integrity (Resolution > Creation).

Estrutura de Pastas / Project Structure

```
project-root/
├── main.py           # Orquestrador Central / Main Orchestrator
├── .env              # Credenciais (Não versionado) / Credentials (Not
versioned)
├── src/
│   ├── bronze/      # Ingestão / Ingestion
│   ├── silver/      # Transformação / Transformation
│   ├── gold/        # Regras de Negócio / Business Rules
│   ├── sla_calculation.py # Motor de Cálculo / Calculation Engine
│   └── validate_pipeline.py # Auditoria de Dados / Data Auditing
└── data/            # Armazenamento Local / Local Storage (Git Ignored)
```